

Disseny d'una xarxa neuronal *autoencoder* per detecció d'anomalies en inversors fotovoltaics

Pau Agustí Fernandez

Grau en Enginyeria Informàtica

Treball dirigit per: Jordi Planes Cid

Departament d'Informàtica i Enginyeria Industrial

C/ de Jaume II, 69, 25001 Lleida

paf3@alumnes.udl.cat

Resum

Els objectius d'aquest projecte són estudiar i comprendre el funcionament d'una xarxa neuronal *autoencoder* per la detecció d'errors en l'inversor d'un sistema fotovoltaic. S'analitzaran les dades per identificar els diferents errors que afecten aquests inversors. Es desenvoluparan diversos models de xarxes neuronals *autoencoder*, que seran entrenats i avaluats per detectar de manera precisa dades anòmales. Els resultats obtinguts seran estudiats i interpretats per millorar la detecció d'anomalies. L'objectiu final és crear eines amb intel·ligència artificial que facilitin el manteniment i la resolució ràpida de fallades en els sistemes fotovoltaics, reduint costos i temps d'intervenció.

1. Introducció

El desenvolupament de les tecnologies solars té el seu inici en la dècada de 1860, motivat per l'expectació del límit dels combustibles fòssils, en concret del carbó. Aquesta preocupació creixent va fer que el 1883, Charles Fritt fabriqués per primer cop una cèl·lula solar, un dispositiu molt poc eficient, però mostrant al món que podia obtenir-se energia de la radiació solar [1]. Aquest desenvolupament es va veure estancat fins a la dècada de 1990, quan aquest va tornar a emprendre força degut a la preocupació pel canvi climàtic i els avenços tecnològics. En aquestes últimes dècades, a causa de l'augment de subvencions per a la integració i desenvolupament d'aquesta tecnologia, cada cop s'opta més per aquesta font d'energia com a part parcial o total en el seu subministrament. Fins avui en dia, diferents empreses d'arreu del món proporcionen solucions pel muntatge i manteniment d'aquests sistemes fotovoltaics. I és que aquests sistemes, no només són muntats i funcionals, sinó que necessiten un manteniment.

La motivació principal d'aquest treball és poder aconseguir una eina que pugui facilitar el manteniment i detectar una fallada en un instant de temps, o fins i tot, poder preveure-la en un sistema fotovoltaic, en concret en un inversor fotovoltaic.

El creixement exponencial de la intel·ligència artificial i conseqüentment, l'aprenentatge automàtic, ha obert un ventall de possibilitats per crear eines per a poder reduir l'impacte d'aquest manteniment, permetent una reducció de costos.

Els objectius principals del projecte són:

- Estudiar i comprendre xarxa neuronal *autoencoder* [2].
- Analitzar les dades per poder entendre els diferents errors que afecten els inversors fotovoltaics.
- Assolir models capaços de detectar dades anòmales.

2. Desenvolupament del treball

En la primera fase del desenvolupament del treball, es fa un estudi del marc teòric necessari. En aquest es descriuen conceptes bàsics de l'aprenentatge automàtic, de les xarxes neuronals i de les dades que utilitzarem. Es fa èmfasi en la procedència de les dades i una breu descripció dels sistemes fotovoltaics, per poder acabar d'entendre la importància dels inversors fotovoltaics. Havent assolit el coneixement rellevant als punts descrits, es fa una anàlisi per poder indicar i identificar que dades es consideren com normals i que dades es consideren com anòmales, arribant a la conclusió que les dades anòmales són instant de temps consecutius en què l'inversor hauria d'estar generant corrent altern, però que per un motiu desconegut es troba sense generar-ne.

El segon pas, després de fer l'estudi teòric, es comença amb el desenvolupament dels models. Els models implementats i les diferents proves realitzades poden trobar-se en el repositori del projecte [3]. Aquests models es caracteritzen per reproduir en la sortida les dades que han estat entrades, però després de fer-ne una codificació i descodificació. La primera part de l'*autoencoder*, s'encarregarà de comprimir les dades d'entrada amb un valor inferior de variables, mentre que la segona part, a partir d'aquest vector de variables de mida inferior, intentarà reproduir de la forma més acurada possible la dada entrada. Aquests models, només seran entrenats amb dades normals, per tant, seran capaços de reproduir amb precisió dades d'instants de temps sense fallada, però quan es passi una dada anòma, aquests al reproduiran amb més error. L'error és el que utilitzarem per mesurar que tan bona és una reproducció, i també per poder establir un l·lindar. L'error és la distància que hi ha entre la dada real i la seva reproducció. El l·lindar serà usat per classificar les dades. Quan una dada reproduïda obtingui un error per sota del l·lindar, la considerarem dada normal, i quan obtingui un error per sobre del l·lindar la considerarem dada anormal.

Els diferents models implementats es distribueixen en experiments, i cada un d'aquest ha estat pensat amb objectius diferents, amb una complexitat de menys a més:

- El primer experiment té com a objectius fer una primera aproximació als *autoencoders* i la detecció d'anomalies.
- El segon experiment té com a objectiu assolir una detecció més precisa fent ús de la tecnologia LSTM.
- El tercer experiment té com a objectiu poder assolir una predicció de les anomalies, fent ús de les implementacions dels models dels experiments anteriors, però modificant l'entrenament que reben.

3. Resultats generats

Els resultats es descriuran seguint la matriu de confusió i veient com de bons són els models reproduint les dades normals i anòmales. El primer experiment ha obtingut uns resultats molt optimistes. Fent ús del llindar, la classificació de dades que pot assolir-se d'aquest model és realment precisa, tal com podem veure en la Figura 1.




Figura 1. Experiment 1: matriu de confusió.

Si realitzem la reproducció de les dades d'un dia del qual coneixem l'existència d'una fallada, Figura 2, podem veure com durant l'interval de temps en la que aquesta es produeix, totes les dades estan per sobre del llindar.




Figura 2. Experiment 1: reproducció de dades d'un dia amb fallada.

Per altra banda, si realitzem la reproducció de les dades d'un dia en el que no existeixen fallades, Figura 3, podem veure com la majoria de dades es troben per sota del llindar.




Figura 4. Experiment 1: reproducció de dades d'un dia sense fallada.

Alguns casos puntuals es troben per sobre del llindar de forma aleatòria, però són dades normals detectades incorrectament com anòmales.

En el següent experiment, també s'aconsegueixen resultats optimistes, com indica la matriu de confusió de la Figura 4.




Figura 3. Experiment 2: matriu de confusió.

En el tercer i últim experiment no s'aconsegueix l'objectiu de poder predir les dades anòmales amb un període de temps, i els resultats són els mateixos que els models han donat respectivament en l'experiment 1 i l'experiment 2.

4. Conclusions

Les xarxes neuronals implementades en els tres experiments han demostrat la seva eficàcia en la detecció d'anomalies. Quan un dels models produeix un error per sobre del llindar, tenim una dada anòma que pot indicar una fallada. Si les dades consecutives també són considerades anòmales, podem determinar que l'inversor està en estat de fallada. Els falsos positius són casos aïllats i rarament es troben diversos registres consecutius detectats com anomalies si l'inversor està funcionant correctament.

Els dos primers experiments han obtingut resultats satisfactoris, tot i que el primer ha estat lleugerament més òptim. Això obre un debat sobre la utilitat de models més senzills i ràpids d'entrenar en certes situacions, ja que no sempre són necessaris models complexos o tècniques de processament més avançades per millorar els resultats.

Desafortunadament, el tercer experiment no ha aconseguit els resultats esperats. L'objectiu era detectar patrons per predir errors, però els resultats han estat similars als dels primers experiments. Això pot ser causat per diverses raons, com l'ús d'una tècnica inadequada o la falta d'informació suficient en les dades per preveure les fallades de l'inversor.

Referències

- [1] D. Anderson, «POWER SYSTEM STABILITY WITH RENEWABLE INTEGRATION», 2021.
- [2] D. Bank, N. Koenigstein, i R. Giryes, «Autoencoders»
- [3] P. Agustí, «paupaf3/tfg-anomaly-detection». <https://github.com/paupaf3/tfganomaly-detection>.