



TREBALL FINAL DE GRAU



ESCOLA
POLITÈCNICA SUPERIOR
UNIVERSITAT DE LLEIDA
INSPIRING THE FUTURE

Estudiant: Pau Agustí Fernandez

Titulació: Grau en Enginyeria Informàtica

Títol de Treball Final de Grau: Disseny d'una xarxa neuronal autoencoder per detecció d'anomalies en inversors fotovoltaics

Director/a: Jordi Planes Cid

Presentació

Mes: Juny

Any: 2023

Índex

1. Introducció.....	6
1.1. Objectius.....	7
1.2. Estructura del document	7
2. Marc teòric: Aprenentatge automàtic i definició del problema	8
2.1. Què és l'aprenentatge automàtic?.....	8
2.1.1. Aprenentatge supervisat.....	9
2.1.2. Aprenentatge no supervisat.....	9
2.2. Què és una xarxa neuronal?	9
2.2.1. Estructura d'una xarxa neuronal	10
2.2.2. Capes	11
2.2.2.1. Capa d'entrada	11
2.2.2.2. Capa oculta.....	11
2.2.2.3. Capa de sortida	12
2.2.3. Neurona artificial.....	12
2.2.4. Funció d'activació	14
2.2.5. Xarxa neuronal <i>autoencoder</i>	14
2.2.6. Xarxa neuronal LSTM	16
2.2.7. Detecció d'anomalies amb un <i>autoencoder</i>	16
2.3. Definició del problema.....	17
2.3.1. Inversors fotovoltaics	17
2.3.2. Origen i definició de les dades	18
2.3.2.1. Dades amb paràmetres sobre l'estat dels inversors	18
2.3.2.2. Dades amb informació meteorològica	19
2.3.2.3. Dades de l'estudi de generació real i generació esperada	19
2.3.3. Dades normals i dades anòmales.....	19
2.3.3.1. Dades normals.....	19
2.3.3.2. Dades anòmales	22

3.	Disseny del projecte.....	24
3.1.	Entorn.....	24
3.1.1.	Entorn de desenvolupament	24
3.1.2.	Entorn d'entrenament.....	24
3.2.	Arquitectura del projecte	24
3.2.1.	Preprocessament de les dades	24
3.2.2.	Arquitectura dels experiments i els respectius models.....	27
3.2.2.1.	Experiment 1: detecció d'anomalies amb <i>autoencoder</i>	27
3.2.2.2.	Experiment 2: detecció d'anomalies amb <i>autoencoder</i> LSTM.....	30
3.2.2.3.	Experiment 3: predicció d'anomalies	32
3.2.3.	Avaluació dels models	33
3.2.3.1.	Pèrdues en la reproducció	33
3.2.3.2.	Comparació en la reproducció de dades normals i anòmales.....	34
3.2.3.3.	Càlcul del llindar.....	35
3.2.3.4.	Matriu de confusió i paràmetres derivats	37
4.	Resultats i discussió.....	40
4.1.	Experiment 1: detecció d'anomalies amb <i>autoencoder</i>	40
4.2.	Experiment 2: detecció d'anomalies amb <i>autoencoder</i> LSTM.....	45
4.3.	Experiment 3: predicció d'anomalies	51
5.	Conclusions finals i futur del projecte	52
6.	Bibliografia	54

Índex de figures

Figura 1. Flux de resolució d'un problema amb aprenentatge automàtic.	8
Figura 2. Estructura d'una xarxa neuronal.....	10
Figura 3. Descripció de les parts d'una neurona biològica.	12
Figura 4. Descripció de les parts d'una neurona artificial.	12
Figura 5. Estructura d'una xarxa neuronal <i>autoencoder</i>	15
Figura 6. Arquitectura simplificada d'una cel·la LSTM.	16
Figura 7. Esquema simple de l'estructura d'un sistema fotovoltaic.	18
Figura 8. Gràfic de dades normals, generació de potència de corrent altern real i esperat.	20
Figura 9. Gràfic de dades normals, generació de potència de corrent altern i radiació solar.	20
Figura 10. Gràfic de dades normals amb petites alteracions, generació de potència de corrent altern real i esperat.	21
Figura 11. Gràfic de dades anòmales, generació de potència de corrent altern real i esperat.	22
Figura 12. Gràfic de dades anòmales, generació de potència de corrent altern i radiació solar.	23
Figura 13. Exemple d'un vector entrada en xarxa neuronal <i>autoencoder</i>	26
Figura 14. Exemple d'un vector entrada en xarxa neuronal <i>autoencoder</i> LSTM.	26
Figura 15. Experiment 1: estructura de les capes de la xarxa neuronal <i>autoencoder</i>	27
Figura 16. Representació gràfica de la funció d'activació <i>ReLU</i>	28
Figura 17. Representació gràfica de la funció d'activació <i>Leaky ReLU</i>	29
Figura 18. Representació gràfica de la funció d'activació Sigmoide.	29
Figura 19. Experiment 2: estructura de les capes de la xarxa neuronal <i>autoencoder</i>	30
Figura 20. Exemple gràfic de pèrdues amb pendent negatiu.....	33
Figura 21. Exemple gràfic de pèrdues amb pendent quasi nul.....	34
Figura 22. Comparació de registre original i reconstrucció.	34
Figura 23. Comparació de registre anormal i reconstrucció.	35
Figura 24. Gràfic de distribució de dades normals i anormals segons l'error.	36

Figura 25. Gràfic de distribució de dades normals i anormals segons l'error amb el llindar indicat.	37
Figura 26. Esquema d'una matriu de confusió.	38
Figura 27. Experiment 1: pèrdues en l'entrenament.	40
Figura 28. Experiment 1: comparació de dades normals i reproduccions.	41
Figura 29. Experiment 1: comparació de dades anòmales i reproduccions.	41
Figura 30. Experiment 1: matriu de confusió.	42
Figura 31. Experiment 1: gràfic de distribució de l'error en la reproducció de les dades.	42
Figura 32. Experiment 1: reproducció de dades d'un període de temps aproximat de 27 dies.	43
Figura 33. Experiment 1: reproducció de dades anòmales d'un període temps aproximat de 24h.	43
Figura 34. Experiment 1: reproducció de dades normals d'un període temps aproximat de 24h.	44
Figura 35. Experiment 1: reproducció de dades d'un període de temps aproximat de 27 dies.	44
Figura 36. Experiment 1: reproducció de dades d'un període temps aproximat de 7 dies.	45
Figura 37. Experiment 2: pèrdues en l'entrenament.	45
Figura 38. Experiment 2: comparacions de dades normals i reproduccions.	46
Figura 39. Experiment 2: comparacions de dades anòmales i reproduccions.	46
Figura 40. Experiment 2: matriu de confusió.	47
Figura 41. Experiment 2: gràfic de distribució de l'error en la reproducció de dades.	48
Figura 42. Experiment 2: gràfic de distribució de l'error en la reproducció de dades anòmales.	48
Figura 43. Experiment 2: reproducció de dades d'un període de temps aproximat de 27 dies.	49
Figura 44. Experiment 2: reproducció de dades anòmales d'un període aproximat de 24h.	49
Figura 45. Experiment 2: reproducció de dades normals d'un període aproximat de 24h.	50
Figura 46. Experiment 2: reproducció de dades d'un període aproximat de 5 dies.	50

Figura 47. Experiment 2: reproducció de dades d'un període aproximat de 27 dies.	50
Figura 48. Experiment 2: reproducció de dades d'un període de 7 dies.....	51

Índex d'equacions

Equació 1. Càlcul d'una neurona artificial.	13
Equació 2. Càlcul sumatori de les entrades ponderades pels pesos.	14
Equació 3. Funció d'activació <i>ReLU</i>	28
Equació 4. Funció d'activació <i>Leaky ReLU</i>	29
Equació 5. Funció d'activació Sigmoide.	30
Equació 6. Càlcul del llindar.	36
Equació 7. Càlcul de la sensibilitat.	38
Equació 8. Càlcul de la precisió.	39
Equació 9. Càlcul de l'exactitud.	39

1.Introducció

El desenvolupament de les tecnologies solars té el seu inici en la dècada de 1860, motivat per l'expectació del límit dels combustibles fòssils, en concret del carbó. Aquesta preocupació creixent va fer que el 1883, Charles Fritt fabriqués per primer cop una cèl·lula solar, un dispositiu molt poc eficient, però mostrant al món que podia obtenir-se energia de la radiació solar [1].

Tot i això, a causa del baix cost de les fonts no renovables com el carbó o el petroli, aquest desenvolupament es va veure estancat fins a la dècada de 1990, quan aquest va tornar a emprendre força degut a la preocupació pel canvi climàtic i els avenços tecnològics. En aquestes últimes dècades, a causa de l'augment de subvencions per a la integració i desenvolupament d'aquesta tecnologia, i a la millora del cost d'obtenció de l'energia fotovoltaica, tant particulars com empreses opten cada cop més per aquesta font d'energia com a part parcial o total en el seu subministrament. Fins avui en dia, diferents empreses d'arreu del món proporcionen solucions pel muntatge i manteniment d'aquests sistemes fotovoltaics. I és que aquests sistemes, no només són muntats i funcionals, sinó que necessiten un manteniment.

La motivació principal d'aquest treball és poder obtenir una eina que pugui facilitar el manteniment i detectar una fallada en un instant de temps, o fins i tot, poder preveure-la en un sistema fotovoltaic, en concret en un inversor fotovoltaic.

El creixement exponencial de la intel·ligència artificial i consegüentment, l'aprenentatge automàtic, ha obert un ventall de possibilitats per crear eines per a poder reduir l'impacte d'aquest manteniment i el personal darrere d'aquest, permetent una reducció de costos.

Poder identificar les fallades podria tenir nombroses utilitats, com per exemple, poder indicar als tècnics de manteniment aquestes en el menor temps possible, fent que els sistemes fotovoltaics no perdin productivitat per aquests errors, o inclús poder automatitzar o evitar aquest manteniment.

1.1. Objectius

Els objectius a assolir en el projecte són:

- Estudiar i comprendre el funcionament d'una xarxa neuronal *autoencoder*.
- Estudiar i comprendre el funcionament d'un sistema fotovoltaic simple, i la part d'aquest en la que enfocarem el treball, l'inversor fotovoltaic.
- Analitzar les dades proporcionades per poder entendre els diferents errors que afecten els inversors fotovoltaics.
- Crear i dissenyar diferents models de xarxes neuronals *autoencoders*.
- Entrenar diferents models de xarxes neuronals *autoencoder*.
- Estudiar i comprendre els resultats obtinguts dels diferents models.
- Assolir models capaços de detectar dades anòmales de forma precisa.
- Interpretar una predicció de les dades anòmales.

1.2. Estructura del document

Aquest treball està estructurat en cinc apartats:

El primer apartat proposa una breu introducció a aquest, juntament amb els objectius i la motivació que descriu d'on prové la idea i el perquè del projecte.

El segon apartat del treball fa una introducció teòrica als termes que esmentarem al llarg de la definició dels desenvolupaments i als mètodes utilitzats per assolir els objectius proposats, per tal de permetre al lector poder entendre els desenvolupaments i els resultats obtinguts sense pràcticament necessitat d'un estudi previ.

El tercer apartat descriu els punts bàsics del desenvolupament, com l'entorn on són entrenats els models, una breu anàlisi de les dades que tractaran els models, el preprocessament d'aquestes i l'arquitectura dels models creats. També es defineixen els mètodes utilitzats per poder classificar el rendiment d'aquests.

El quart apartat conté els resultats obtinguts en els diferents experiments i la discussió d'aquests de forma individual.

En el cinquè i últim apartat es fa un estudi global dels resultats, per poder generar unes conclusions finals de tot el projecte i la ruta a seguir per poder continuar en un futur, si així es desitja.

2. Marc teòric: Aprenentatge automàtic i definició del problema

2.1. Què és l'aprenentatge automàtic?

L'aprenentatge automàtic és una branca de la intel·ligència artificial basada en el disseny i la creació d'algoritmes amb capacitat de raonament, d'interpretació de patrons i de presa de decisions [2], [3]. Com el seu nom bé indica, aquests algoritmes assolixen aquestes capacitats gràcies a l'aprenentatge. Aquest descriu un conjunt de tècniques que s'utilitzen per a la resolució de problemes que poden trobar-se en el món real, ben bé igual que la resta de programari informàtic, però l'aprenentatge automàtic destaca per poder-ho fer sense la necessitat de programar explícitament per a resoldre una dificultat.




Figura 1. Flux de resolució d'un problema amb aprenentatge automàtic.

En la Figura 1 podem veure un esquema simple del flux de resolució d'un problema en aprenentatge automàtic. Aquesta metodologia fa ús d'uns casos d'entrenament per poder entrenar l'algoritme, permetent la generació d'un model basat en el coneixement i l'experiència obtinguda. El model, si és degudament entrenat, ha de ser capaç de poder trobar una solució a un nou problema no pertanyent al conjunt d'entrenament. El problema no té perquè pertànyer als casos d'entrenament, però sí que ha de ser un problema del conjunt, no pot entrenar-se un algoritme per la detecció de malalties i esperar que doni resultats en predicció de preus d'estoc. Per tant, en passar un nou problema és capaç d'assolir una solució concreta mitjançant raonament i interpretació de patrons après en els casos d'entrenament.

Si indaguem una mica més en aquest àmbit de la intel·ligència artificial, podem diferenciar entre dues especificacions més, l'aprenentatge supervisat i el no supervisat.

2.1.1. Aprenentatge supervisat

L'aprenentatge supervisat és capaç de deduir una funció d'aproximament a la resolució a partir d'unes dades d'entrenament etiquetades [4]. Per aconseguir les dades etiquetades és necessari forçar un processament de les dades obtingudes i realitzar un estudi per tal de poder-les classificar. Aquest procediment és principalment utilitzat en classificació, regressió i predicció.

La complexitat d'aquest aprenentatge acostuma a ser simple, ja que sol ser necessari de menors quantitats de dades per a poder assolir un model amb capacitat d'aconseguir bons resultats.

2.1.2. Aprenentatge no supervisat

L'aprenentatge no supervisat, respecte a l'anteriorment esmentat, no necessita una interacció prèvia de les dades [4]. És clar, pot ser necessari i molt útil un processament a posteriori de l'entrenament, però les dades no necessiten estar classificades amb anterioritat. Principalment s'utilitza en reducció de dimensió, associació i agrupament de variables, i detecció d'anomalies. La complexitat d'aquest aprenentatge sol ser més elevada respecte a l'aprenentatge supervisat, ja que és el propi model el que ha de ser capaç de poder trobar patrons que puguin discernir.

Cal esmentar que l'aprenentatge no supervisat, no és lliure d'intervenció humana per al processament de dades, és necessari i recomanable l'ús de dades etiquetades per a poder comprovar i validar els resultats del model.

En aquest treball es farà èmfasi en l'aprenentatge no supervisat, i és que farem ús de xarxes neuronals, en concret d'*autoencoders*, que usaran dades sense etiquetar per a la fase d'entrenament i dades prèviament etiquetades per a la validació dels models.

2.2. Què és una xarxa neuronal?

Una xarxa neuronal és un model d'aprenentatge automàtic dissenyat seguint l'estructura real d'un cervell humà. Intenta imitar d'una forma acurada la interacció entre les neurones biològiques, substituïdes en el model per unes neurones artificials [5].

Aquest model es basa en aprendre i millorar la seva precisió a mesura que es processen les dades d'entrenament, modificant valors de cada una de les neurones, fent que un gran nombre de dades sigui molt útil a l'hora de formar i entrenar aquests algoritmes. Això provoca que l'etapa d'aprenentatge pugui ser costosa i comporti un cert temps per poder assolir bons resultats, però un cop el model ha assolit la precisió desitjada, és capaç de poder resoldre un nou problema de forma ràpida.

2.2.1. Estructura d'una xarxa neuronal

Una xarxa neuronal està formada per capes. Dues d'aquestes capes són les que trobem en la part més exterior de la xarxa, la capa d'entrada i la capa de sortida. Aquestes dues capes són les que han d'existir per força, sense elles no podríem passar dades al model, ni rebre el resultat processat. A més d'aquestes dues, existeixen les capes ocultes, les quals no comuniquen amb l'exterior, perquè només es comuniquen entre elles i amb les capes d'entrada i sortida. Alhora, totes les capes estan formades per neurones, que és on es duu a terme el processament.




Figura 2. Estructura d'una xarxa neuronal.

En la Figura 2 podem veure una estructura d'una xarxa neuronal, un exemple que difereix una mica de la xarxa neuronal en la qual es basarà la part experimental d'aquest treball, però és l'exemple més bàsic i comú que podem trobar en buscar informació al respecte. Aquesta xarxa neuronal està formada per quatre capes. A la part esquerra, amb color groc, podem identificar la capa de sortida, formada per tres nodes. Al centre de l'estructura podem identificar dues capes ocultes, en color

vermell, formades cada una d'elles per 5 nodes. I finalment, a la part dreta podem veure la capa de sortida, amb una única neurona, en color blau.

2.2.2. Capes

Com hem definit en l'apartat anterior, *Estructura d'una xarxa neuronal*, una xarxa neuronal està principalment estructurada en capes, però cal veure el perquè d'haver d'organitzar les neurones d'una xarxa.

La necessitat d'organitzar les neurones en capes, principalment és causat per la limitació que tenen aquestes en transmetre informació. Una neurona artificial és capaç només de transmetre una informació limitada, més en concret, és capaç de transmetre un únic valor. El fet d'organitzar aquestes en capes, com podem veure en la Figura 2, ens permet transmetre un vector o una matriu de valors.

En la definició de l'estructura d'una xarxa hem definit tres tipus de capes, però cal fer èmfasis en cada una d'elles per poder entendre el seu objectiu i les seves responsabilitats en el model.

2.2.2.1. Capa d'entrada

La capa d'entrada rep els paràmetres que formen el conjunt de dades, i passen aquests a la capa oculta de primer nivell. El nombre de nodes que formen aquesta capa serà igual al nombre de paràmetres per dada, és a dir, serà igual a l'amplitud de les dades a processar. Tornant a la Figura 2, aquesta capa d'entrada, en color groc, rebria una dada composta per tres paràmetres.

2.2.2.2. Capa oculta

Les capes ocultes són les encarregades de realitzar el màxim cos computacional [6]. Aquestes poden aparèixer en diferents cardinalitats segons l'arquitectura del model. Com bé indica el nom, i podem veure en la Figura 2, en color vermell, són capes aïllades de l'exterior de la xarxa i cada capa processa les dades minimitzant una funció d'error mitjançant funcions d'activació i de pes.

Un exemple relacionat amb el que veurem en la part experimental, és com en la codificació de dades, cada capa mitjançant càlculs és capaç de reduir el nombre de paràmetres entrats, eliminar els que puguin ser redundants i unir paràmetres que puguin estar relacionats. D'aquesta forma, cada capa oculta té la responsabilitat de donar valor a paràmetres que puguin ser determinants i restar valor a altres que puguin ser insignificants.

Un nombre elevat de capes ocultes augmentarà el cost de l'entrenament i l'execució, però també tindrà capacitat de poder resoldre problemes més complexos.

2.2.2.3. Capa de sortida

La capa de sortida és l'encarregada de donar la solució al cas que s'ha entrat, per tant, el nombre de neurones artificials que la constitueixin serà el nombre de paràmetres que tindrà la solució donada pel model. Si tornem a la Figura 2, podem veure com la capa de sortida, en color blau, està formada per un únic node, per tant, aquest model tindrà un únic valor com a resultat.

2.2.3. Neurona artificial

La neurona artificial, també anomenada neurona de McCulloch-Pitts o node, és l'element bàsic d'una xarxa neuronal, i és l'element que forma les capes. La idea i el funcionament de les neurones artificials sorgeix de l'estudi i anàlisi de les neurones biològiques.




Figura 3. Descripció de les parts d'una neurona biològica.




Figura 4. Descripció de les parts d'una neurona artificial.

En la Figura 3 podem veure l'estructura i les parts d'una neurona biològica, i en la Figura 4 podem veure l'estructura i les parts d'una neurona artificial. Aquestes

segones, com hem mencionat, es troben ideades a partir de les neurones biològiques, i consegüentment les parts de les biològiques poden identificar-se en una neurona de McCulloch-Pitts [7].

En les seves parts, no només podem identificar una similitud gràfica, sinó que podem reconèixer un funcionament, unes característiques i uns propòsits comuns, ja que les neurones artificials pretenent mimetitzar les característiques més importants d'una neurona real. En la Figura 4 podem identificar les entrades, el que serien les dendrites en la Figura 3, que és la part encarregada de rebre la informació provinent d'altres neurones que han transmès aquesta informació a partir de la seva sortida, que en una neurona biològica serien els botons terminals de l'axó. El processament de la informació el realitzen el sumatori i la funció d'activació, que serien el cos cel·lular, la beina de mielina, la cèl·lula de Schwann i el nòdul de Ranvier de la Figura 3. Aquestes parts s'encarreguen de processar les dades entrades i produir, o no, una sortida.

El funcionament d'una neurona artificial sembla senzill, i de forma abstracta ho és. Però, necessitem veure d'una forma més específica que passa amb les entrades i com es genera la sortida. A grans trets, el que una neurona artificial duu a terme és un sumatori de les entrades, multiplicant aquestes pels seus pesos associats i processant el resultat per una funció d'activació, que activarà o no la neurona per traslladar el seu resultat a la propera neurona de la següent capa. Aquest càlcul és representat mitjançant l'Equació 1

$$y(t) = F \left(\sum_{i=0}^m w_i(t) \cdot x_i(t) \right)$$

Equació 1. Càlcul d'una neurona artificial.

on:

- $x_i(t)$ és el valor de l'entrada en t .
- $w_i(t)$ és el pes de l'entrada en t .
- $y(t)$ és el valor de sortida en t .
- F és la funció d'activació.

Per tant, una part important i que suposarà una gran incògnita en la creació i desenvolupament d'una xarxa neuronal, i que haurà de ser resolta per part nostra mitjançant estudi i proves, serà la funció d'activació. Aquesta afectarà els resultats que obtindrem del model i, per tant, no ha de passar-se per alt.

2.2.4. Funció d'activació

La funció d'activació en una neurona artificial no és més que una funció que transmet la informació generada pel sumatori a la sortida. S'anomenen així perquè oposen una barrera que cal sobrepassar per poder prosseguir amb la informació i transmetre-la a la següent neurona. Aquesta barrera no cal sobrepassar-la sempre, sinó que és utilitzada per a realitzar un filtratge de la informació. No tota la informació que introduïrem en la xarxa, i conseqüentment en les neurones, serà determinant.

$$x(t) = \sum_{i=0}^m w_i(t) \cdot x_i(t)$$

Equació 2. Càlcul sumatori de les entrades ponderades pels pesos.

Les funcions d'activació són funcions no lineals, és a dir funcions de grau superior a 1, i gràficament tenen una curvatura quan es representen. Aquestes són les encarregades de donar complexitat al model, ja que el sumatori de les entrades multiplicat pels pesos (Equació 2) resultaria en una equació lineal.

La predicció d'una xarxa neuronal depèn del nombre de capes, del nombre de nodes, de l'entrenament i d'altres factors, però la funció d'activació escollida per a cada capa hi tindrà un paper molt crucial, a més de ser una part necessària. Una xarxa neuronal sense fer ús de cap funció d'activació, no seria més que una equació lineal, és a dir, una equació de grau 1. Aleshores, limitar la complexitat només reduiria la capacitat de la xarxa de poder aprendre i resoldre problemes. No volem un model capaç de resoldre equacions lineals, sinó que volem un model amb suficient complexitat per a poder resoldre problemes del món real, els quals serien un gran repte per l'humà sense fer ús de mecanismes computacionals d'aprenentatge automàtic. Cal remarcar, que normalment, però no sempre, solen utilitzar-se funcions d'activació no lineals, però hi poden haver excepcions [8].

2.2.5. Xarxa neuronal *autoencoder*

Una xarxa neuronal *autoencoder* és un tipus de xarxa neuronal d'aprenentatge no supervisat. La particularitat d'aquesta xarxa és que no intenta realitzar una classificació o una predicció, sinó que intenta reproduir les dades entrades de la forma més acurada [9]. Per poder-ho fer, ha de tenir el mateix nombre de neurones en la capa d'entrada i en la capa de sortida.

Reproduir les mateixes dades que han estat entrades seria molt senzill. Si les dades de la capa d'entrada són passades a la capa de sortida sense cap processament, es reproduirien perfectament. És clar que aquest no és el funcionament d'un

autoencoder. L'objectiu és poder reproduir les mateixes dades, però després d'una codificació i descodificació d'aquestes.




Figura 5. Estructura d'una xarxa neuronal *autoencoder*.

En la Figura 5 podem veure l'estructura d'un *autoencoder*, format per una part de codificació, o codificador, que seria la part formada pels nodes en color vermell. El codificador és la part encarregada de, com indica el seu nom, codificar les dades. Donat un conjunt de dades de mida n , ha de ser capaç de reduir-lo a un conjunt de dades de mida m , sent $m < n$, però sense perdre informació rellevant del conjunt de dades de mida superior que ha tingut com entrada. D'aquesta forma, la part de descodificació, o descodificador, que formen els nodes de color groc, realitza la inversa. Rep un conjunt de dades de mida m i en retorna un altre de mida n , sent $n > m$. El descodificador, a partir de la sortida del codificador, ha de poder reproduir les dades que el codificador ha tingut com entrada, com hem especificat, des d'un conjunt més petit de dades.

En la Figura 5 es poden veure uns nodes de color blau, nodes comuns, que formen part de la capa de sortida del codificador i de la capa d'entrada del descodificador, el qual és el coll d'ampolla del model.

Un *autoencoder* sempre ha de tenir un mínim de tres capes:

- La capa d'entrada, amb un nombre n de nodes.
- La capa o capes ocultes, amb un nombre m de nodes, sent $m < n$.
- La capa de sortida, amb un nombre n de nodes, igual que la capa d'entrada.

2.2.6. Xarxa neuronal LSTM

En la part experimental, també es farà ús d'una xarxa neuronal *autoencoder* LSTM, però primer cal definir quin és el significat d'aquest acrònim. LSTM (Long Short-Term Memory) és una tècnica utilitzada per al processament de seqüències de dades repetitives, com és el nostre cas d'ús [10]. Per tant, ja que les nostres dades repeteixen seqüències molt semblants entre dies, i durant molts dies, és una tècnica que ens pot proporcionar un avantatge respecte a les altres xarxes neuronals.

Una xarxa neuronal LSTM, a diferència de les xarxes neuronals recurrents convencionals, té una estructura més complexa que permet recordar informació d'un major espai de temps.




Figura 6. Arquitectura simplificada d'una cel·la LSTM.

Com podem identificar en la Figura 6, cada node LSTM té tres portes:

- Porta d'oblit: té la responsabilitat de decidir quina informació ha de descartar-se de la memòria, ja sigui perquè ha deixat de ser rellevant o perquè ha pogut quedar obsoleta.
- Porta d'entrada: té la responsabilitat de decidir quina informació ha d'afegir-se a la memòria. Aquesta informació nova s'afegeix a la memòria a través d'una funció d'activació que determina la importància d'aquesta.
- Porta de sortida: té la responsabilitat de decidir quina informació s'ha de transmetre al següent node. Mitjançant una funció d'activació determina que part de la memòria s'ha d'utilitzar per generar la sortida que es transmetrà.

2.2.7. Detecció d'anomalies amb un *autoencoder*

Quan parlem de detecció d'anomalies, ens referim a fer una classificació de les dades, entre dades normals i dades anormals, o anòmales, sent aquestes dades que no corresponen al correcte funcionament del mecanisme o flux a estudiar. Aquesta classificació no és realitzada directament pel model, sinó que necessita un processament de la informació retornada pel model per a poder fer la classificació.

Un *autoencoder* aprèn a reproduir les dades entrades. Si l'entrenament d'aquest es fa amb dades normals, aquest aprèn a reproduir només dades normals. Quan el model rep per entrada una dada anormal, aquest intenta reproduir-la i, com només té coneixement per reproduir dades normals, ho realitzarà de forma incorrecta.

Per saber si una dada ha estat o no correctament reproduïda pel model, utilitzarem l'error, el qual és la distància o àrea que podem trobar entre la dada original i la recreada. És així com una xarxa neuronal d'aquest tipus ens permet classificar i identificar dades anormals.

Per a poder calcular aquest llinar, necessitem obtenir la mitjana de l'error en la reproducció de dades i la desviació estàndard. Amb la suma d'ambdós valors aconseguim el llinar o *threshold*, que ens servirà per poder classificar les dades. Les dades reproduïdes per l'*autoencoder* amb un error per sobre d'aquest llinar, són susceptibles de ser dades per les quals aquest model no ha estat entrenat, és a dir, dades anòmales.

2.3. Definició del problema

2.3.1. Inversors fotovoltaics

Les plaques solars estan formades per diverses cèl·lules fotovoltaïques que, quan reben energia solar, reaccionen fent moure els electrons. Aquesta reacció produeix electricitat de corrent continu. L'energia és recollida i transmesa a l'inversor fotovoltaic, o emmagatzemada en una bateria si es manté en corrent continu.

Un inversor fotovoltaic, o inversor solar, és un equip que s'encarrega de transformar l'energia produïda per una instal·lació fotovoltaica. Aquesta genera i transmet energia en corrent continu, i l'inversor fotovoltaic és l'encarregat de transformar-la en corrent altern pel seu ús o per la seva transmissió a la xarxa elèctrica.

Si l'inversor fotovoltaic falla, l'energia produïda per la placa solar es perd provocant una fuga d'energia, a menys que sigui emmagatzemada en una bateria de corrent continu. Aquests inversors poden trobar-se des d'instal·lacions per a particulars fins a instal·lacions de plantes fotovoltaïques.




Figura 7. Esquema simple de l'estructura d'un sistema fotovoltaic.

En la Figura 7 podem veure un esquema simple d'un sistema fotovoltaic. El panell fotovoltaic genera energia, electricitat en corrent continu, i un regulador de corrent s'encarrega de distribuir aquesta en corrent continu cap a una bateria, o altres elements que puguin consumir-la. La resta de l'energia serà passada a l'inversor fotovoltaic, que s'encarregarà de convertir-la en corrent altern. Si l'inversor falla, i no hi ha ningú que pugui consumir tota l'energia en forma de corrent continu, ens trobarem en una fuga d'energia, ja que l'inversor fotovoltaic no estarà processant-la i consegüentment no estarà traslladant-la a la xarxa elèctrica.

Per aquest motiu és necessari conèixer quan l'inversor ha fallat, i quan aquest necessita manteniment.

2.3.2. Origen i definició de les dades

Les dades utilitzades provenen de SM Technology And Services 2050, partner tecnològic de Group Saltó, empresa encarregada d'oferir solucions pel monitoratge i control d'instal·lacions fotovoltaiques. Aquestes han estat cedides per col·laboració amb Marc Mir, CTO de SM Technology And Services 2050.

Les dades són formades per diferents fitxers que contenen informació, però nosaltres farem ús només de les dades que en considerem rellevants.

2.3.2.1. Dades amb paràmetres sobre l'estat dels inversors

La informació està formada per dades de set inversors fotovoltaics en intervals d'un minut durant tot un any, del juny del 2020 fins al juny del 2021, ambdós mesos inclosos. Les dades respectives a cada inversor es poden trobar en un fitxer per separat. En aquestes dades podem trobar informació respectiva als següents punts:

- Data i hora exacta en la qual s'ha pres el registre.

- Power AC (W): potència en corrent altern generat en aquell instant de temps per l'inversor. La unitat de mesura és el Watt.
- Kwh (Accumulated): quantitat d'energia generada fins a l'instant de temps actual, paràmetre acumulatiu. La unitat de mesura és el Quilo Watt Hora.
- Voltage AC (V): voltatge de corrent altern mesurat en l'instant de temps en diferents fases. La unitat de mesura és el Volt.
- Freq. AC (Hz): freqüència generada en la sortida de l'inversor per l'instant de temps. La unitat de mesura és l'Hertz.

2.3.2.2. Dades amb informació meteorològica

La informació meteorològica està formada per dades en intervals d'un minut durant sis mesos, del gener de 2021 fins al juny d'aquest mateix any, ambdós mesos inclosos. Les dades respecte a cada un dels mesos es pot trobar en un fitxer per separat. En aquestes dades podem trobar informació respectiva als següents punts:

- Data i hora exacta en la qual s'ha pres el registre.
- Temperatura ambient en l'instant de temps mesurat.
- Temperatura aproximada del mòdul fotovoltaic.
- Radiació en diferents punts de la cèl·lula receptora.
- Radiació total.

Tota la informació i registres pertanyen a la mateixa instal·lació fotovoltaica, per tant, la informació meteorològica pot ser usada amb relació a la informació de qualsevol dels inversors. Ens seria de molta utilitat poder analitzar la radiació solar que estan rebent els panells fotovoltaics, ja que no tenim registres sobre el que passa en l'energia que entra en l'inversor en forma de corrent altern.

2.3.2.3. Dades de l'estudi de generació real i generació esperada

Són estudis de generació real i generació esperada per cada un dels set inversors, amb un registre cada 15 minuts, del juny del 2020 fins al juny del 2021, ambdós mesos inclosos. Aquesta informació ens pot ser útil per ajudar a identificar casos d'errors o altres casos que explicarem en l'apartat *Dades normals i dades anòmales*.

2.3.3. Dades normals i dades anòmales

2.3.3.1. Dades normals

Les dades poden ser classificades en normals i anòmales. En aquest cas, una dada normal es considera quan l'inversor funciona de forma correcta, per tant, quan la seva generació de potència de corrent altern té un valor pròxim al valor esperat.

Té relació amb la radiació solar que estan rebent les plaques fotovoltaïques que transfereixen la seva potència en corrent continu a l'inversor.




Figura 8. Gràfic de dades normals, generació de potència de corrent altern real i esperat.

En la Figura 8 podem veure un gràfic d'un dia de la generació de potència de corrent altern d'un inversor. El gràfic va de les 00:00 fins a les 23:59 del mateix dia. En aquest podem apreciar com en les primeres i últimes hores del dia, la generació de potència és zero, perquè són hores en les quals no hi ha radiació. També podem veure com en l'interval de temps de 06:00 fins a 19:00, hi ha una corba quasi perfecta de generació de potència, tant real com esperada. És per això que considerem com normal aquesta dada. Per poder-ho entendre millor cal veure el gràfic de la Figura 9, en el que es mostra la generació de potència de corrent altern respecte la radiació solar.




Figura 9. Gràfic de dades normals, generació de potència de corrent altern i radiació solar.

En aquesta Figura 9 podem veure com la corba de generació de potència respecta la corba de radiació solar que rebem. Tot i això, no és perfecta, veiem uns pics a les 09:00, a les 11:00 i a les 13:00 en les que podem apreciar una caiguda de la radiació. Aquest efecte pot ser causat per diferents motius, però principalment és degut a ombres que poden afectar en la percepció de la radiació solar en el nostre sensor. Un altre fet remarcable és que tot i veure pics en la radiació solar, no veiem pics en la generació de potència. Acusem la distribució del sensor com a culpable d'aquest efecte, ja que la radiació solar no es mesura en cada una de les plaques fotovoltaïques. La radiació ha disminuït, per exemple per un núvol, que fa ombra sobre el sensor de radiació, però no genera ombra sobre els panells solars associats a l'inversor. Aquest efecte ve lligat amb l'exemple de dades de la Figura 10.




Figura 10. Gràfic de dades normals amb petites alteracions, generació de potència de corrent altern real i esperat.

En la Figura 10 podem observar un efecte semblant a l'anterior però a la inversa. Podem tenir un gràfic de radiació perfecte, un gràfic de potència esperada també amb una corba perfecta, però podem tenir petites variacions o pics en la generació de potència real. Això un cop més pot ser causat per diferents circumstàncies, com per exemple que un núvol amb la seva ombra ha pogut cobrir durant uns minuts unes plaques fotovoltaïques, però aquest no ha tingut perquè cobrir i afectar el sensor de radiació solar. Aquesta dada no la considerem com anormal.

El cas dels núvols i les ombres pot ser el cas més bàsic, però és clar, pot ser donat per altres circumstàncies, com per exemple errors en el sensor de radiació solar o inclús l'inici d'un comportament erroni o fallada de l'inversor. És per això que en les dades no corregirem aquests casos, pot ser que arribin a donar informació preventiva de la fallada d'un inversor, però també afegirà dificultat en la reproducció de les dades i podem trobar-nos falsos positius en la cerca de dades anòmales.

2.3.3.2. Dades anòmales

Les dades que si considerarem anòmales són aquelles on l'inversor no és capaç de transmetre potència en corrent altern, tot i que si hi esperem una generació d'energia ja que la radiació solar en aquell instant de temps ho permet.




Figura 11. Gràfic de dades anòmales, generació de potència de corrent altern real i esperat.

En el gràfic de la Figura 11 podem veure un clar exemple de dades anormals, dades en les quals trobem una fallada de l'inversor. Primerament, igual que en les dades normals, trobem que a les primeres i últimes hores del dia no tenim generació de potència real, i l'esperada també és zero, però a mesura que avança el dia trobem una desincronització de la corba de generació real i esperada. L'esperada manté una corba semblant a les dades normals anteriorment analitzades, però no és el cas de la generació real. En la generació real apreciem uns pics a les 09:00 i a les 10:00 que poden ser deguts a una fallada, o a una circumstància menor que ha pogut provocar unes ombres durant uns minuts. No obstant, de 10:30 a 14:30 aproximadament, trobem un interval de temps en el que l'inversor ha deixat de generar per complet energia en corrent altern. Per corroborar que és per culpa d'una fallada hem de revisar la Figura 12, en la que veurem si la radiació solar ha pogut tenir algun efecte en aquest succés.




Figura 12. Gràfic de dades anòmales, generació de potència de corrent altern i radiació solar.

Continuant amb l'explicació anterior i veient ara el gràfic de la radiació solar, Figura 12, podem veure que en l'interval que el generador no ha estat produint energia en corrent altern, hi havia uns valors elevats de radiació, generant una corba amb pics, però amb incongruències respecte a la generació d'energia en corrent altern de l'inversor.

Això demostra que els panells solar havien d'estar produint corrent continu i que és molt improbable que un núvol o ombra hagi pogut estar cobrint els panells durant un temps aproximat de 4 hores, sense arribar a cobrir el sensor de radiació. Per tant, podem afirmar que és una dada anòma i que molt probablement aquest efecte és per un error en l'inversor, o en algun punt pròxim a aquest dins el sistema fotovoltaic.

3.Disseny del projecte

3.1. Entorn

3.1.1. Entorn de desenvolupament

L'entorn de desenvolupament està format per dos ordinadors diferents, un amb sistema operatiu Linux i l'altre amb Windows. Amb l'ús d'un control de versions, en aquest cas Git, ens permetrà poder treballar amb total facilitat i mantenir la implementació actualitzada en ambdós sistemes. També es farà ús d'entorns virtuals, els quals són tractats amb Anaconda 3, una interfície que facilita la instal·lació de llibreries i la creació d'entorns virtuals. Així podrem mantenir les mateixes llibreries en els dos sistemes que s'usaran pel desenvolupament i també ens serà útil per si és necessari executar el projecte en qualsevol altre sistema.

El llenguatge de programació escollit és Python, degut a la facilitat en buscar recursos d'informació respecte al tema que tractarem. També per la quantitat de llibreries d'aprenentatge automàtic i la integració que aquestes tenen entre elles.

3.1.2. Entorn d'entrenament

L'entorn d'entrenament s'ha realitzat només en el sistema amb Windows, pel fet que és disposa d'un millor hardware i conseqüentment de major rendiment. No és necessari tenir un sistema d'alt rendiment per a poder entrenar els models, ja que les dades no són pesades i no tenen una amplitud gran. Per aquest motiu, vaig escollir el sistema de Windows per poder entrenar de forma més ràpida els models i poder agilitzar les implementacions i la realització de proves. Per tant, els models s'han entrenat localment fent ús d'un sistema Windows amb una GPU Nvidia GeForce RTX 3080.

3.2. Arquitectura del projecte

3.2.1. Preprocessament de les dades

Abans de començar amb la creació dels models i el processament que faran aquestes de les dades, cal veure i realitzar si s'escau, un preprocessament d'aquestes dades. Tot el codi, al qual serà referent aquesta secció, pot trobar-se en el repositori del projecte [11].

Aquest preprocessament té l'objectiu de modelar les dades per poder optimitzar el procés que duren a terme els models, i poder evitar errors tant en l'entrenament com en la prova degut a dades incorrectes.

Cal esmentar que abans d'aquest pas, ja s'ha portat a cap una selecció de les dades rellevants, descartant dades que no aportaven informació, dades repetides en diferents fitxers i dades buides, ja que en molts dels fitxers aportats hi havien dades repetides o camps que es mantenien a 0 durant tots els registres de temps.

Després de la selecció esmentada, es realitza una comprovació per veure si les dades tenen registres de temps buits, per evitar major confusió en les dades. Veiem que pràcticament es troben tots els registres de temps, per cada minut, excepte en algun cas molt puntual en el que pot haver-hi un salt d'un minut. Es considera no rellevant i en els resultats no són apreciables canvis en aplicar regressió lineal per poder omplir aquests intervals inexistents.

A continuació, es creen els *datasets* que utilitzarem tant per l'entrenament com per l'avaluació dels models. Per crear aquests, s'uneixen les dades mesurades en l'inversor i les dades meteorològiques, usant el camp que indica la data i hora en la qual es va prendre el registre, camp que ambdós comparteixen. S'ha tingut en compte que si hi ha algun instant de temps que no es troba en els dos conjunts de dades, s'ignora. Es realitza així per evitar tenir registres on les dades meteorològiques es troben buides i l'inversor mostra un correcte funcionament i viceversa. Un cop units els dos *datasets*, s'elimina el camp que indica la data i l'hora, ja que no és un valor que volem tenir en compte per la detecció d'errors. En entrenar el model amb dades ja existents, són dates anteriors a l'actual i no volem que en l'aprenentatge del model pugui influir un camp que mai serà igual a mesura que augmenti el temps.

Sí que podríem considerar rellevant l'hora, perquè a simple vista podem deduir que a certes hores l'inversor mai rebrà ni transformarà energia, i en altres ho farà pràcticament sempre, però és preferible donar aquesta responsabilitat a les dades meteorològiques. Aquestes tindran informació més acurada i tindran en compte exemples tan bàsics com dies ennuvolats, dies de boira, les diferents estacions o qualsevol altre fenomen que pugui afectar a la radiació que els panells solars perceben.

Un cop realitzat el pas anterior ens trobem amb 7 *datasets*, cada un d'ells amb 6 mesos d'informació amb registres cada 1 minut, és a dir, un total aproximat de 259.200 registres per inversor, juntament amb la informació meteorològica.

Finalment, s'aplica una normalització a les dades. La normalització és un procés important per preparar les dades abans d'entrenar una xarxa neuronal. L'objectiu de la normalització és adaptar les columnes del conjunt de dades a una escala

comuna, per evitar que una columna que tingui valors molt diferents d'altres característiques pugui afectar el procés d'entrenament. Existeixen diferents mètodes, però l'escollit en aquests experiments és la normalització mix-max, que escala les dades perquè totes es trobin en un rang comprès entre 0 i 1.

Aquesta normalització no es va fer en les primeres implementacions, però després de fer ús d'aquesta i de la funció Sigmoide en la capa de sortida dels models, es va poder apreciar una notable disminució de l'error en reproduir dades normals i conseqüentment una millora en els resultats dels *autoencoders*. Es definirà millor aquesta deducció en l'apartat *Arquitectura dels experiments i els respectius models*.

En alguns experiments, la normalització no és l'últim pas en el preprocessament de les dades, sinó que hi existeix un pas més. Aquest últim pas es realitza per als models que fan ús de la tècnica LSTM breument definida anteriorment.




Figura 13. Exemple d'un vector entrada en xarxa neuronal *autoencoder*.




Figura 14. Exemple d'un vector entrada en xarxa neuronal *autoencoder LSTM*.

Per un model no LSTM, només es té com entrada una dada d'un instant de temps, com l'exemple de la Figura 13 en el qual es pot veure un vector dels paràmetres a, b, c, d i e en l'instant de temps t .

Per una xarxa neuronal LSTM és té com entrada un conjunt d'instantis de temps, en els que trobem el vector de l'instant de temps que volem processar, i nombre n de vectors d'instantis de temps anteriors. En la Figura 14 podem veure en color vermell el vector que correspon a l'instant de temps t , que correspon a l'instat de temps a processar, i en color groc podem veure els vectors de dades que corresponen als instantis de temps anteriors [12]. Això, com veurem en els experiments, suposarà un major cost d'entrenament, però amb els avantatges que la tècnica LSTM ens entrega.

Per poder obtenir les dades en aquest format, farem ús d'un algoritme propi que les formatarà augmentat la dimensió.

3.2.2. Arquitectura dels experiments i els respectius models

En aquesta secció es definiran els diferents experiments, els models utilitzats i el perquè de la seva arquitectura. En cada un dels experiments s'ha escollit el model amb el qual s'han aconseguit els millors resultats, però fins a obtenir aquests models ha estat necessari realitzar diferents implementacions provant diferents arquitectures i entrenaments.

Les implementacions dels models, els experiments i els seus resultats finals poden trobar-se en el repositori del projecte [11].

3.2.2.1. Experiment 1: detecció d'anomalies amb *autoencoder*

El primer experiment consisteix a poder realitzar d'una forma acurada una detecció de les dades anòmales, basant-nos en una estructura bàsica d'*autoencoder*.




Figura 15. Experiment 1: estructura de les capes de la xarxa neuronal *autoencoder*.

L'estructura del model que en aquest experiment ha assolit més bons resultats, és la representada en la Figura 15. Les capes que la formen són les següents:

1. Capa d'entrada: L'entrada a la xarxa neuronal és $input = 12$, un vector de paràmetres unidimensional que han estat processats com es descriu en la secció 3.2.1 Preprocessament de les dades.
2. *Dense* de dimensió 24 + Activació *Leaky ReLU*.
3. *Dense* de dimensió 18 + Activació *Leaky ReLU*.
4. *Dropout* de 0'1.
5. *Dense* de dimensió 12 + Activació *Leaky ReLU*.
6. *Dense* de dimensió 8 + Activació *Leaky ReLU*.

7. *Dropout* de 0'1.
8. *Dense* de dimensió 6 + Activació *Leaky ReLU*.
9. Coll de botella: *Dense* de dimensió 4 + Activació *Leaky ReLU*.
10. *Dense* de dimensió 6 + Activació *Leaky ReLU*.
11. *Dense* de dimensió 8 + Activació *Leaky ReLU*.
12. *Dropout* de 0'1.
13. *Dense* de dimensió 12 + Activació *Leaky ReLU*.
14. *Dense* de dimensió 18 + Activació *Leaky ReLU*.
15. *Dropout* de 0'1.
16. *Dense* de dimensió 24 + Activació *Leaky ReLU*.
17. Capa de sortida: *Dense* de dimensió 12 + Activació Sigmoide.

Per poder assolir aquesta estructura, l'experiment va realitzar-se en fases, cada una d'elles enfocada a un aspecte concret del model. Per exemple, en la primera fase es va fer un profund estudi per poder identificar una selecció de les funcions d'activació, i en la segona fase es va continuar fent proves per veure si era útil afegir normalització en la sortida dels nodes. Aquests aspectes pot ser que no siguin rellevants per ser descrits aquí. D'altra banda, gràcies a les proves realitzades en aquestes fases, es poden destacar punts claus del model.

Comencem per un punt que ha estat molt rellevant sobretot en l'obtenció de resultats, l'elecció de les funcions d'activació. La funció d'activació *Leaky ReLU* ha estat escollida després de fer diferents proves amb la seva predecessora *ReLU*, que és generalment la funció utilitzada en xarxes neuronals *autoencoders* [13].




Figura 16. Representació gràfica de la funció d'activació *ReLU*.

$$ReLU(x) = \max(0, x)$$

Equació 3. Funció d'activació *ReLU*.




Figura 17. Representació gràfica de la funció d'activació *Leaky ReLU*.

$$\text{LeakyReLU}(x) = \max(0.01 \cdot x, x)$$

Equació 4. Funció d'activació *Leaky ReLU*.

Les diferències entre aquestes dues, és que la funció d'activació *ReLU*, Figura 16, pels valor negatius té un pendent nul, fent que aquests mai puguin ser inferiors a 0, tal com s'indica en l'Equació 3.

La funció *Leaky ReLU*, Figura 17, pels valors negatius té un pendent inferior a la dels valors positius, però no zero, com es pot veure en l'Equació 4. Això aporta certs avantatges com evitar la saturació de les neurones en xarxes profundes, o inclús ser més efectiva quan es treballa amb grans volums de dades. Per aquests motius va ser escollida com una candidata, i en fer les proves es van obtenir millors resultats.

Continuant amb les funcions d'activació, hi ha un punt molt concret de la xarxa neuronal on la funció d'activació no és la *Leaky ReLU*, sinó la funció Sigmoide i aquesta té, valgui la redundància, una funció molt específica. Recordem que les dades d'entrada al model són prèviament normalitzades, fent que tots els paràmetres es trobin en una escala entre 0 i 1. En l'entrenament de la xarxa neuronal es va veure com certs paràmetres es disparaven, provocant que l'error en la reproducció de dades augmentés.




Figura 18. Representació gràfica de la funció d'activació Sigmoide.

$$\text{Sigmoide}(x) = \frac{1}{1 + e^{-x}}$$

Equació 5. Funció d'activació Sigmoide.

La funció d'activació Sigmoide, Figura 18, sempre retorna valors entre 0 i 1, ambdós inclosos, seguint l'Equació 5 [13]. D'aquesta manera, es força a la xarxa neuronal a donar com a sortida sempre paràmetres continguts entre el rang anteriorment esmentat, que és el mateix rang que s'aplica en la normalització en el preprocessat de les dades.

Un altre punt important de la xarxa, és l'ús de les capes *Dropout* [14]. Aquestes només són rellevants en l'entrenament del model, ja que en l'execució d'aquest no afecten. S'utilitzen per evitar l'efecte d'*overfitting* i per fer que la xarxa sigui més robusta al soroll que pot trobar-se en el conjunt de dades [15]. El mètode que fan servir les capes *Dropout* és desactivar cert nombre de neurones de forma aleatòria, amb una probabilitat indicada per paràmetre, per evitar que les neurones properes puguin generar dependència entre elles mateixes, és a dir, millorar el seu rendiment individual sense dependre de les relacions amb neurones veïnes.

3.2.2.2. Experiment 2: detecció d'anomalies amb *autoencoder* LSTM

El segon experiment es basa a poder realitzar d'una forma acurada una detecció de les dades anòmales, igual que en el primer experiment, però intentant buscar millors resultats i identificar diferents patrons no visibles a simple vista.




Figura 19. Experiment 2: estructura de les capes de la xarxa neuronal *autoencoder*.

L'estructura del model que en aquest experiment ha assolit els resultats més optimistes, és la representada en la Figura 19. Les capes que la formen són les següents:

1. Capa d'entrada: L'entrada a la xarxa neuronal és $input \cdot timesteps = 72$, on $input = 12$ i $timesteps = 6$. Una matriu de paràmetres bidimensional que han estat processats com es descriu en la secció *Preprocessament de les dades*.
2. *LSTM* de dimensió 48 + Activació *Leaky ReLU*.
3. *BatchNormalization*.
4. *LSTM* de dimensió 36 + Activació *Leaky ReLU*.
5. *BatchNormalization*.
6. *LSTM* de dimensió 24 + Activació *Leaky ReLU*.
7. *Dropout* de 0'1.
8. *LSTM* de dimensió 18 + Activació *Leaky ReLU*.
9. *BatchNormalization*.
10. *LSTM* de dimensió 12 + Activació *Leaky ReLU*.
11. *BatchNormalization*.
12. *LSTM* de dimensió 8 + Activació *Leaky ReLU*.
13. *Dropout* de 0'1.
14. Coll de botella: *LSTM* de dimensió 6 sense retorn de seqüències + Activació *Leaky ReLU*.
15. RepeatVector amb el nombre d'instants de temps anteriors.
16. *LSTM* de dimensió 8 + Activació *Leaky ReLU*.
17. *BatchNormalization*.
18. *LSTM* de dimensió 12 + Activació *Leaky ReLU*.
19. *BatchNormalization*.
20. *LSTM* de dimensió 18 + Activació *Leaky ReLU*.
21. *Dropout* de 0'1.
22. *LSTM* de dimensió 24 + Activació *Leaky ReLU*.
23. *BatchNormalization*.
24. *LSTM* de dimensió 36 + Activació *Leaky ReLU*.
25. *BatchNormalization*.
26. *LSTM* de dimensió 48 + Activació *Leaky ReLU*.
27. *Dropout* de 0'1.
28. Capa de sortida: *TimeDistributed* + *Dense* de dimensió 12 + Activació Sigmoide.

Aquesta estructura té molt en comú amb la definida en el primer experiment. Els punts claus descrits en el primer experiment, s'han continuat aplicant en les implementacions posteriors.

Tot i això, aquesta implementació està caracteritzada per fer ús de capes, i conseqüentment nodes, *LSTM*. Aquestes no són alimentades amb un vector

unidimensional com en el model de l'experiment anterior, sinó que per entrada tenen una matriu bidimensional de l'instant de temps a analitzar i un nombre *timesteps* de vectors d'instant de temps anteriors, com està descrit en l'apartat 3.2.1 *Preprocessament de les dades*. La sortida d'aquestes capes pot ser amb o sense retorn de seqüències, és a dir, retornar un instant de temps com a vector, ignorant els *timesteps* instants de temps posteriors o retornar la matriu de vectors de forma completa. L'única capa que té la sortida sense retorn de seqüències és la capa número 14, la capa que forma el coll de botella.

En aquest model també es fa ús de les capes *BatchNormalization* [16]. Aquestes, en un primer moment, no van ser usades, però després de diferents iteracions del model van ser necessàries. Com que el volum de dades és superior, per augmentar la dimensionalitat d'aquestes, i que les capes LSTM no només són més complexes sinó que són recurrents, el model va trobar-se amb el problema dels gradients explosius. El problema dels gradients explosius provocava que en l'etapa d'entrenament hi hagués grans canvis en les pèrdues, que aquestes agafessin valors nuls, i que els resultats globals no estiguessin a l'altura. Fent ús de les capes de normalització *BatchNormalization* va permetre realitzar entrenaments més exhaustius, i conseqüentment, va permetre que les pèrdues en la reproducció de dades del model mantinguessin una distribució més localitzada i estable.

3.2.2.3. Experiment 3: predicció d'anomalies

En el següent i últim experiment, farem un pas més enllà per intentar obtenir predicció dels errors coneguts. Fins ara hem estat buscant detectar aquests errors en l'instant de temps que estan succeint, però el propòsit i objectiu és assolir una detecció de forma precisa instants de temps abans que l'error succeeixi. Serà necessari fer una detecció de patrons comuns en registres anteriors a la fallada i intentar trobar una relació entre aquests.

Per intentar assolir l'objectiu de l'experiment, no farem cap arquitectura nova, sinó que utilitzarem les implementacions realitzades anteriorment.

La diferència en aquests models respecte en els anteriors experiments, serà l'entrenament que rebran. Es realitzaran diferents entrenaments evitant les dades de n instants de temps anteriors a la fallada. Per tant, entrenarem els models amb les dades que ho hem fet fins ara, però eliminant no només les dades dels errors, sinó també n registres anteriors, on n prendrà els valors 1000, 2000 i 4000.

3.2.3. Avaluació dels models

Per l'avaluació dels models s'han tingut en compte diferents paràmetres i resultats. Aquests s'exposaran i discutiran en l'apartat de resultats però s'ha considerat oportú descriure el perquè de cada estudi.

3.2.3.1. Pèrdues en la reproducció

Com una xarxa neuronal *autoencoder* té com a propòsit reproduir amb exactitud una dada entrada, cal comprovar com de bé és capaç de predir de nou la dada entrada. Per tant, el primer pas realitzat per a tots els models és veure les pèrdues del vector reproduït respecte al vector entrat. Això es realitza mitjançant la funció de pèrdues.

A l'hora d'entrenar un model, indiquem quin és el conjunt d'entrada, i hi indiquem també el conjunt esperat. És així com el model en l'entrenament s'ajusta al resultat que ha d'assolir, i també ens permet veure la millora que ha assolit durant totes les iteracions. Seria suficient en veure les pèrdues en l'última iteració, però poder visualitzar la corba que aquestes pèrdues han realitzat en el transcurs de l'entrenament, ens dona informació valuosa en el desenvolupament dels models.




Figura 20. Exemple gràfic de pèrdues amb pendent negatiu.

Per exemple, en la Figura 20 veiem que les últimes iteracions segueixen una tendència de pendent negatiu, és possible que amb més entrenament el model obtingui més bons resultats, o almenys un error inferior en la reproducció de les dades.

A més, també ens permet identificar la distància en l'error de les dades amb què s'està entrenant, i les dades que el model està utilitzant per validació. Ens interessa obtenir valors petits per ambdós casos, no ens serveix que les dades d'entrenament tinguin un error molt baix de reproducció, si després en executar el model obtenim prediccions poc acurades i amb soroll.




Figura 21. Exemple gràfic de pèrdues amb pendent quasi nul.

Per altra banda, en la Figura 21 podem veure que les últimes iteracions indiquen un pendent pràcticament nul. Ens pot indicar que el model està estancat i no reduirà més les seves pèrdues. També es pot veure com l'error en les dades d'entrenament i validació es troba superposat, per tant, s'ha aconseguit que el model sigui capaç de reproduir dades diferents de les d'entrenament amb molta precisió.

3.2.3.2. Comparació en la reproducció de dades normals i anòmales

Un cop estudiades les pèrdues de reproducció en les dades normals en el procés d'entrenament, anem a veure com el nostre model reproduceix un registre. Per fer-ho d'una forma més visual, hem fet ús de gràfics que mostren en l'eix horitzontal tots els paràmetres que formen el registre, i en l'eix vertical els valors d'aquests paràmetres. En aquests es mostra el registre real i el reproduït.




Figura 22. Comparació de registre original i reconstrucció.




Figura 23. Comparació de registre anormal i reconstrucció.

En els exemples de la Figura 22 i la Figura 23 es pot veure la dada original i la reproducció d'aquesta mateixa, i en un fons vermell l'error o distància entre aquestes dues. L'exemple de la Figura 22 és una dada normal i l'exemple de la Figura 23 és una dada anòmala. En aquest exemple, el model tindria dificultats per poder reproduir una dada anòmala, tenint una distància considerable entre el vector original i el vector generat. Per altra banda, la dada normal hauria pogut ser reproduïda d'una forma més precisa. La informació proporcionada per aquests gràfics és molt significativa. Ens està demostrant que el model pot reproduir les dades correctament, però no pot fer-ho quan hi ha un error. És clar que és un sol exemple dels milers de dades que un model processa, però ja ens dona factors per poder apostar pel model.

3.2.3.3. Càlcul del llinar

El llinar és el límit que ens indicarà que dada reproduïda és normal i quina és anòmala. El que es fa és comparar l'error en la reproducció, distància o diferència entre la dada real i la predicció, amb aquest llinar. Si es troba per sota, es considera una dada normal, i si es troba per sobre es considera una dada no normal, una anomalia. Hi ha diferents mètodes per calcular aquest, com per exemple escollir un valor de forma manual que estigui per sobre de l'error en la reproducció de dades normals, però per sota en la reproducció de dades anòmales, o inclús mètodes que les pròpies llibreries, com *scikit-learn*, proporcionen.

Aquí s'ha optat per una mesura simple, però que s'adapta al nostre cas d'ús, i per cada model pot ser escollit de forma automàtica. Es prediuen tots els registres del *dataset* de test, i s'obté l'error de reproducció de cada un d'ells. Es realitza una mitjana aritmètica de tots aquests valors i es suma un cop la desviació estàndard.

En agafar la mitjana d'error de la reproducció de les dades de test, que sabem que són només dades normals, obtenim una aproximació de l'error que realitza el nostre model en reproduir una dada. Però, no és suficient ja que necessitem tenir en compte la dispersió d'aquests valors. Un exemple ràpid seria, si tenim la meitat de les dades

amb un error igual a 0, i l'altra meitat amb un error igual a 1, resultaria en un valor de 0'5 d'error mitjà en la reproducció de les dades. Però no és real, ja que dins d'aquest rang entrarien la meitat de les dades que tenen un error igual a 1, i són dades correctes. Es per això que fem ús de la desviació estàndard. Si continuem amb l'exemple anterior, la desviació estàndard seria de 0'5. La suma de la mitjana i la suma de la desviació estàndard tindria com a resultat 1, per tant el nostre llindar seria 1. Totes les dades per sobre d'aquest serien considerades anòmales.




Figura 24. Gràfic de distribució de dades normals i anormals segons l'error.

En el gràfic de la Figura 24 es pot veure una distribució de dades normals i anormals respecte al seu error MSE (*Mean Squared Error*) [17]. Pel càlcul del llindar només farem ús de les dades normals, i per fer-ho aplicarem la fórmula

$$threshold = mean(losses) + std(losses)$$

Equació 6. Càlcul del llindar.

on:

- *threshold* és el valor del llindar.
- *losses* és el vector que conté l'error de reproducció de cada un dels registres.
- *mean(losses)* és el càlcul de la mitjana del vector *losses*.
- *std(losses)* és el càlcul de la desviació estàndard del vector *losses*.

Seguin amb l'exemple de la Figura 24, primer de tot és necessari calcular la mitjana amb la qual obtindrem el valor 0'01728. Després és necessari realitzar el càlcul de la desviació estàndard, que ens donarà un valor de 0'01439. Per tant, fem la suma d'ambdós valors i assolim el valor 0'03167 com a llindar [18].




Figura 25. Gràfic de distribució de dades normals i anormals segons l'error amb el llindar indicat.

En la Figura 25, es pot veure la representació de les dades amb el llindar prèviament calculat. Aquest llindar, indicat amb la línia de color groc, ens mostra com a partir del model que ha predit aquest conjunt de dades, indicariem quines dades són anòmales. Totes les dades amb un error superior al llindar ho serien considerades, i les inferiors serien dades normals. Aquest model ha fet una bona predicció, les distribucions de dades normals i anormals es troben clarament representades i dividides pel llindar, però no ho fa de forma exacta. Es poden veure dades normals, amb un error per sobre del llindar, i dades anòmales per sota del llindar. Segons el cas d'ús aquest llindar pot calcular-se de diferents formes, o inclús fixar a mà després de fer una anàlisi dels resultats, però cal tenir en compte diferents factors:

- Si fixem el llindar en valors alts, el model i l'anàlisi de les dades no marcarà dades normals com dades anòmales, però passarà per alt dades anòmales com dades normals.
- Si fixem el llindar en valors baixos, el model i l'anàlisi de les dades ens marcarà dades normals com dades anòmales, però no passarà per alt, o ho farà en un grau més baix, dades anòmales com dades normals.

Cal trobar un equilibri entre ambdues situacions per poder fixar un llindar òptim.

3.2.3.4. Matriu de confusió i paràmetres derivats

Per poder mesurar els resultats obtinguts en cada model i entrenament, ens ajudarem de la matriu de confusió, que fent ús del llindar, mostrarà d'una forma gràfica i senzilla els resultats que estan aconseguint els nostres models [19]. A més a més, ens serà útil per entendre paràmetres com la sensibilitat (*Recall*), la precisió (*Precision*) i l'exactitud (*Accuracy*). No només ens serveix per calcular aquests paràmetres, però seran els que utilitzarem, mesurarem i compararem entre models.




Figura 26. Esquema d'una matriu de confusió.

En la Figura 26 es pot veure un esquema bàsic d'una matriu de confusió per una classificació binària, és a dir de dues cel·les. Cada cel·la té un significat, i els descriurem respecte al nostre cas d'ús, en els que considerem els valors *True* com dades anòmales i els valors *False* com dades normals.

- *True Positive* (TP): dades anòmales amb una predicció correcta. L'error està per sobre del llindar.
- *False Positive* (FP): dades normals amb una predicció incorrecta. L'error està per sobre del llindar, per tant es marquen com dades anòmales.
- *False Negative* (FN): dades anòmales amb una predicció incorrecta. L'error està per sota del llindar, per tant es marquen com normals.
- *True Negative* (TN): dades normals amb una predicció correcta. L'error en la predicció està per sota del llindar.

A partir dels paràmetres d'aquestes cel·les calcularem:

- Sensibilitat (*Recall*): proporció de dades reals anòmales, que han estat identificades com dades anòmales. Utilitzada per mesurar la "quantitat". Com més alt és el valor millor. La seva fórmula és:

$$Recall = \frac{TP}{TP + FN}$$

Equació 7. Càlcul de la sensibilitat.

- Precisió (*Precision*): proporció de dades identificades com anòmales que realment són anòmales. Utilitzada per mesurar la “qualitat”. Com més alt és el valor millor. La seva fórmula és:

$$Precision = \frac{TP}{TP + FP}$$

Equació 8. Càlcul de la precisió.

- Exactitud (*Accuracy*): proporció de dades identificades correctament com normals o anòmales respecte a totes les dades. Com més alt és el valor millor. La seva fórmula és:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Equació 9. Càlcul de l'exactitud.

4. Resultats i discussió

4.1. Experiment 1: detecció d'anomalies amb *autoencoder*

En ser la primera implementació, el primer contacte amb les llibreries i les dades va suposar que fos l'experiment que més iteracions i temps necessités per poder obtenir resultats, i sobretot per poder identificar errors que en un primer moment van haver de superar-se.

En la primera fase de l'avaluació del model, realitzem un estudi de l'error, calculat amb MSE, en el que apreciem com en poques iteracions, l'error del model és capaç de disminuir fins a assolir un nivell molt optimista, visible en la Figura 27. Això és degut a que l'entrenament s'ha realitzat en poques èpoques, però sent ajustat en petits subconjunts de dades. En l'entrenament l'error assolit per les dades d'entrenament suposa un valor de 0'00066972, i l'error en les dades de validació és un valor de 0'00062284. Considerarem el model com un possible candidat a tenir bon resultats, per l'acurada reproducció de les dades i per la poca diferència entre el valor d'error del set d'entrenament i del set de test.




Figura 27. Experiment 1: pèrdues en l'entrenament.

En el pas següent validem, d'una forma més visible, que la reproducció de les dades és realitza correctament per les dades que són normals, però no per a les dades anòmales. Posarem l'exemple d'unes dades normals i d'unes dades de fallades.




Figura 28. Experiment 1: comparació de dades normals i reproduccions.

En la Figura 28 podem veure com les dades normals i les seves reproduccions segueixen un patró pràcticament idèntic. És un cas ideal, no perfecte perquè encara és visible l'error en algun dels paràmetres, però ho considerarem com a reproduccions satisfactòries.




Figura 29. Experiment 1: comparació de dades anòmales i reproduccions.

En la Figura 29 veiem el contrari amb l'exemple definit anteriorment. Podem veure com les reproduccions disten bastant dels registres reals, però és exactament el que estem buscant, al tractar-se de dades anòmales.

Ambdós figures continuen indicant que el model pot ser vàlid per al propòsit que ha estat creat, ja que és capaç de reproduir dades correctes amb un marge d'error molt petit, i de reproduir les dades anòmales amb un marge d'error bastant superior.

A continuació calculem la mitjana de l'error i la desviació estàndard en la reproducció de dades únicament normals, per poder obtenir el llinar, obtenint com mitjana el valor 0'0012109, com desviació estàndard el valor 0'0045038, i per tant, com llinar obtenim el valor 0'0057147.




Figura 30. Experiment 1: matriu de confusió.

La Figura 30 mostra la matriu de confusió calculada amb el llindar prèviament especificat. Aquesta es troba representada amb tant per u i normalitzada sobre els registres reals. Un cop més, el resultat és optimista, indicant-nos que un 92% de les dades anormals han estat reconegudes correctament com dades anormals i el 99% de les dades normals han estat identificades correctament com dades normals. D'aquesta matriu de confusió extraïem la sensibilitat $Recall = 0'9237$, la precisió $Precision = 0'9900$ i l'exactitud $Accuracy = 0'9572$.




Figura 31. Experiment 1: gràfic de distribució de l'error en la reproducció de les dades.

A continuació, executant el model per a un subconjunt de dades de poc més de 40000 registres, obtenim que pràcticament totes les dades normals es troben agrupades en uns valors baixos d'error en la reproducció, mentre que les anòmales estan agrupades en uns valors d'error superior, tal com es pot veure en la Figura 31. El llindar, marcat amb color groc, mostra el punt de tall per a la classificació que realitzarem de forma

automàtica de les dades. A simple vista sembla que el llindar podria trobar-se en valors una mica més elevats, per no detectar falsos positius en les dades anòmales, però com ja ha estat discutit, aquest pot establir-se i calcular-se de diferents formes segons la preferència que puguem tenir a detectar falsos positius o a no detectar positius reals.

L'últim estudi dels resultats del primer experiment i del model implementat en aquest, es la identificació de dades anòmales en un període de temps.




Figura 32. Experiment 1: reproducció de dades d'un període de temps aproximat de 27 dies.

En la Figura 32 es representen les dades d'un interval aproximat de 27 dies seguits. En aquesta també es troba marcat el llindar amb una línia vermella. En aquest període existeix un error, un error conegut en el dia 11 de l'interval, entre el registre 12786 i 13025. El model permet identificar aquest error a causa de que l'instant en el que es produeix la fallada, les dades assolixen uns valors d'error elevats. Tot i això, en molts dels dies es troben dades identificades com errònies. Tornant a la discussió anterior, si s'augmentés el valor del llindar, evitariem aquests falsos positius.




Figura 33. Experiment 1: reproducció de dades anòmales d'un període temps aproximat de 24h.

La Figura 33 mostra la representació més detallada de l'error esmentat anteriorment, i podem veure com de forma seguida, un gran nombre de registres obtenen valors d'error molt superiors al llindar, que permeten identificar amb exactitud una fallada, i més si són comparats amb registres normals.




Figura 34. Experiment 1: reproducció de dades normals d'un període temps aproximat de 24h.

La Figura 34 mostra els registres d'un interval de temps aproximat de 24 hores, en el que no es produeix cap fallada. És un dels dies amb més registres detectats com falsos positius, per tant ens estem posant en els pitjors dels casos, però tot i això es pot veure una gran diferència respecte a la Figura 33. Els falsos positius no apareixen de forma contínua, sinó que ho fan a l'atzar, i a més els valors d'errors que aquests assolixen són inferiors als valors d'error de les dades realment anormals.

Per acabar de corroborar les conclusions extretes d'aquests registres, ho compararem amb altres registres que contenen fallades conegudes, concretament dues.




Figura 35. Experiment 1: reproducció de dades d'un període de temps aproximat de 27 dies.

En aquest interval de temps d'aproximadament 27 dies, trobem dos dies amb fallades, els dies 11 i 17 de l'interval, entre els registres 12760 i 13056, i els registres 20086 i 20325, respectivament. Un cop més, es poden identificar clarament els errors per sobre del llindar, però sí que tornem a trobar dades normals amb error per sobre del llindar.




Figura 36. Experiment 1: reproducció de dades d'un període temps aproximat de 7 dies.

En la Figura 36, podem veure amb més detall ambdós dies que contenen fallades, i els dies entre aquests. Veient clarament els dies erronis amb gran part dels registres amb errors per sobre del llindar.

Però, tots els dies amb fallades esmentats fins aquest punt, tenen una cosa en comú, només poden ser identificats quan els registres corresponen a hores on la llum solar i la meteorologia permeten que hi hagi generació solar. De fet, si una fallada s'estengués en més d'un dia, no seríem capaç d'identificar els registres d'hores nocturnes com erronis. Això és degut al format i contingut de les dades, i la base en la qual es fomenta per identificar les fallades.

4.2. Experiment 2: detecció d'anomalies amb *autoencoder LSTM*

Cal recordar que aquest model per entrada i sortida té matrius, amb l'instant de temps actual i n instants de temps posteriors. El model que ha assolit més bons resultats, i que es descriurà a continuació, utilitza matrius de 6 vectors o registres, és a dir, el vector actual i 5 vectors d'instants de temps conseqüents anteriors.




Figura 37. Experiment 2: pèrdues en l'entrenament.

L'error, calculat amb MSE, obté valors considerablement baixos en les primeres èpoques del model, però en la Figura 37 podem veure que la pendent és continuada tot i que de forma més discreta, fins a pràcticament estancar-se. En l'entrenament l'error absolut per les dades d'entrenament suposa un valor de 0'012 i l'error en les dades de validació és d'un valor de 0'013. Els valors es troben molt pròxims i en rangs baixos, per tant el resultat és optimista, i ens permet concloure que el model és capaç de reproduir dades normals de forma acurada tot i no haver passat mai aquestes pel model.

Posant l'exemple d'una dada normal i una dada anòma, podem veure com l'error d'ambdues dista considerablement.




Figura 38. Experiment 2: comparacions de dades normals i reproduccions.

En la Figura 38 es pot veure com les dades normals i les reproduccions són pràcticament idèntiques i que l'error entre ambdós registres és ínfim. Ens trobem amb certa variació en l'error de les reproduccions, però en tots els casos, el rang de valors es manté prou pròxim als valors de les dades normals, i distant dels valors de dades de fallades, com podrem apreciar a continuació.



Figura 39. Experiment 2: comparacions de dades anòmales i reproduccions.

Per altra banda, en la Figura 39 es pot veure com les dades anòmales i les seves reproduccions no tenen pràcticament res a veure, l'error entre aquests registres és molt elevat. El rang de valors d'error que les reproduccions de les dades anòmales assoleixen són de gran variació, però aquests disten molt de l'error en la reproducció de dades normals, per tant no suposarà problema establir un llindar que ens permetrà classificar-les.

Aquests resultats ens indiquen que el model s'ha aproximat al seu propòsit, degut a que la reproducció d'una dada normal és capaç de fer-ho de forma considerablement correcta, mentre que la reproducció d'una dada anòmla la realitza amb un marge d'error molt elevat. El següent pas es poder calcular i establir un llindar, amb el que generar i estudiar la matriu de confusió.

Calculem la mitjana de l'error i la desviació estàndard en la reproducció de dades únicament normals, per poder obtenir el llindar, obtenint com mitjana el valor 0'0019385, com desviació estàndard el valor 0'0058014, i per tant, com llindar obtenim el valor 0'0077399.




Figura 40. Experiment 2: matriu de confusió.

La matriu de confusió del model, representada gràficament en la Figura 40, calculada a partir del llindar que acabem de definir, es troba representada amb tant per u i normalitzada sobre els registres reals. Els resultats, seguint la línia de les primeres etapes de la validació, són optimistes. La matriu indica que un 89% de les dades anòmales han estat reconegudes correctament com dades anòmales i el 96% de les dades normals també han estat correctament identificades com el que són. Dels següents resultats podem extreure la sensibilitat $Recall = 0'8900$, la precisió $Precision = 0'9621$ i la exactitud $Accuracy = 0'9273$.




Figura 41. Experiment 2: gràfic de distribució de l'error en la reproducció de dades.

Executem el model sobre un subconjunt de dades de poc més de 40000 registres per a poder veure la distribució d'aquestes respecte l'error. Trobem que pràcticament totes les dades normals es troben en valors d'error inferiors a 0'05 segons podem veure visualment, però realment es troben en valors molt més baixos. De fet hem la mitjana d'error per les dades normals és de 0'0019385, però pràcticament no es veuen les dades de fallades. D'aquest gràfic no podem extreure gaire informació rellevant degut a la distribució que aquest mostra.

Veient el gràfic de distribució de les dades anormals, podem extreure algunes conclusions. En la Figura 42, veient la distribució que segueixen les dades de fallades i el punt on s'ha establert el llindar, en color groc, podem concloure que la majoria d'aquestes s'estableixen per sobre del llindar, però encara en tenim que es troben per sota.




Figura 42. Experiment 2: gràfic de distribució de l'error en la reproducció de dades anòmales.

Aquest fenomen produirà que algunes dades anòmales siguin qualificades com dades normals tot i no ser-ho, però tornant al debat de com establir el llindar, si establim

aquest en un punt més baix, ens trobarem moltes dades normals que passaran com anòmales sense ser-ho.

Per últim, realitzarem un anàlisi de la detecció d'anomalies en un període de temps.




Figura 43. Experiment 2: reproducció de dades d'un període de temps aproximat de 27 dies.

En la Figura 43, on es troben representades les dades d'un interval aproximat de 27 dies seguits, podem identificar certes dades anòmales. Més en concret, entre les dades 12786 i 13025 hi trobem un conjunt en el que destaquen dades anòmales. Han estat detectades correctament com errònies, degut a que en aquell interval de temps és produeix una fallada. També pot trobar-se un instant de temps, aproximadament sobre el registre 6000 en el que la dada reproduïda ho ha fet amb un valor d'error molt elevat, però és irrellevant degut a ser un cas aïllat.




Figura 44. Experiment 2: reproducció de dades anòmales d'un període aproximat de 24h.

En aquesta Figura 44 podem veure les dades del dia que es va produir la fallada, i podem veure com durant un conjunt aproximat de 300 dades, equivalent a 300 minuts, les dades són totes detectades com anòmales, marcant exactament el període que l'inversor va deixar de funcionar.




Figura 45. Experiment 2: reproducció de dades normals d'un període aproximat de 24h.

La Figura 45 correspon a un període aproximat de 24 hores, en les que no es produeix cap fallada. Es pot veure com algunes dades són marcades com anòmales, però no s'hi pot trobar cap interval en el que existeixi un seguit de dades amb error per sobre del llindar. Per tant, aquestes dades són falsos positius, indiquen registres normals com anormals, i realment no existeix cap fallada en aquest interval.




Figura 46. Experiment 2: reproducció de dades d'un període aproximat de 5 dies.

Si comparem un dia amb una fallada real existent amb els seus dies anteriors, podem veure una diferència considerable en l'error de reproducció de les dades i com en el dia de la fallada no hi ha registres aleatoris detectats com anòmales, sinó que s'hi pot trobar un conjunt seguit de dades detectat completament com anòmal. En la Figura 46, podem veure representats 5 dies, els 4 primers són dies sense fallades, fins aproximadament les 5500 dades, i l'últim és un dia amb una fallada.




Figura 47. Experiment 2: reproducció de dades d'un període aproximat de 27 dies.

En l'interval representat en la Figura 47, hi podem trobar dos fallades, corresponents als dies 11 i 17 de l'interval, entre els registres 12760 i 13056, i els registres 20086 i 20325, respectivament. Es poden identificar els errors al veure un subconjunt de registres per sobre del llindar. En aquest gràfic també podem trobar dos registres, o dades, corresponents a minuts aleatoris, en el que la seva reproducció ha resultat en un error molt elevat. Es consideren redundants per no seguir cap patró ni lògica aparent i ser casos aïllats.




Figura 48. Experiment 2: reproducció de dades d'un període de 7 dies.

En la Figura 48, es poden tornar a veure els errors descrits anteriorment, però representats en un interval menor de temps per poder obtenir una vista més detallada. Aquest interval correspon a aproximadament 7 dies, sent el primer i l'últim dies amb fallades. Trobem que l'error en els dies normals és considerablement alt, però tot i així és possible identificar el dies amb fallades si seguim els patrons on trobem un conjunt de dades detectades com anòmales de formes seguida.

4.3. Experiment 3: predicció d'anomalies

Tal i com s'observa en el repositori del projecte [11] els resultats obtinguts van ser similars als anteriors experiments realitzats. Després d'executar diferents proves i entrenar els models evitant les dades de n instants de temps anterior a les fallades, tal com s'indica en *Experiment 3: predicció d'anomalies*, es conclou que els resultats no són suficientment òptims com per predir les fallades. Tot i això, els models obtinguts en aquest experiment permeten detectar les anomalies de la mateixa manera que ho feien les xarxes en els experiments anteriors. Per tant, entrenar el model amb aquesta modificació de les dades d'entrada no és suficient per poder detectar-hi patrons que ens permetin assolir l'objectiu de predicció. Cal tenir en compte que el *dataset* pertany a dades reals, i que la seva naturalesa i la informació que contenen els registres pot ser una barrera a l'hora d'aconseguir una predicció.

5. Conclusions finals i futur del projecte

Durant el desenvolupament del projecte s'han anat assolint els diferents objectius proposats per aquest, i es descriuran a continuació.

Les xarxes neuronals implementades i entrenades en qualsevol dels 3 experiments ens permeten la detecció d'anomalies. Aquestes, són identificades amb l'ús de llindar, però segueixen un patró que ens permet deduir que està ocorrent una fallada amb molta precisió, i evitant errors per possibles falsos positius. Quan algun dels models reproduceix una dada amb un error per sobre del llindar, tenim una dada anòmla que probablement sigui una fallada però, si les dades d'instants de temps conseqüentment següents també són considerades anòmlas, ens indiquen que l'inversor es troba en una fallada. Això és degut a que els falsos positius que s'han trobat en els models solen ser casos molt aïllats, i rarament es troben més de 3 o 4 registres seguits detectats com anomalies si l'inversor no es troba en un estat de fallada.

Un altre punt important, que ha estat discutit breument en els resultats, és sobre el llindar i el valor d'aquest. En els resultats dels experiments s'ha vist com certes dades han estat catalogades com anòmlas sense ser-ho, i que havent augmentat el llindar es podria haver evitat. En aquest treball s'ha decidit calcular-se així per que aquestes dades no han suposat una barrera per la detecció de fallades, i perquè en augmentar el llindar, també hauríem passat per alt dades que realment si eren anòmlas.

Ambdós primers experiments per la detecció d'anomalies han assolit bons resultats, inclús resultats molt propers, però el primer experiment ha assolit, per poc, uns resultats més optimistes. Això obre les portes a debat, degut a que el primer experiment està compost per un model més simple, efectiu, i molt més ràpid d'entrenar. Veiem com per alguns casos no son necessaris models més complexes o tècniques de processament més elevat, per poder millorar els resultats.

El tercer i últim dels experiments, malauradament no ha assolit els resultats esperats. El seu objectiu era poder detectar patrons per indicar una predicció de l'error, però ha acabat tenint els mateixos resultats que els primers experiments. Això pot ser degut a diferents factors, com no haver utilitzat una tècnica correcta per assolir-ne els objectius o simplement, la pròpia naturalesa de les dades. No sabem fins quin punt les dades contien informació suficient per preveure aquestes fallades en l'inversor, i una possibilitat és que aquestes no ho permetin.

Les dades utilitzades per aquest projecte han estat dades reals, les quals han aportat una dificultat extra per anar a cegues. No s'havia provat mai res amb aquest conjunt de dades i no sabíem ben bé si podríem assolir cap dels objectius, però afortunadament hem pogut assolir la majoria dels objectius del projecte, excepte la predicció de les fallades.

A nivell personal, l'execució d'aquest treball m'ha permès tenir una introducció a la detecció d'anomalies, al processament de dades, al desenvolupament de xarxes neuronals i a l'estudi dels resultats aconseguits pels models, augmentant així els coneixements assolits sobre aprenentatge automàtic.

El futur del projecte té un ventall de possibilitats ampli, però principalment totes enfocades en assolir la predicció d'anomalies i veure si les dades ho permeten. Es podrien també millorar els resultats per la detecció d'anomalies, però pot ser que per aquest camí no hi hagi gaire més per on continuar. Per altra banda, podrien utilitzar-se diferents models, realitzant noves implementacions o fent ús de xarxes ja existents, per intentar trobar patrons en instants de temps previs als estats de fallada, intentant assolir la predicció.

6. Bibliografia

- [1] D. Anderson, «POWER SYSTEM STABILITY WITH RENEWABLE INTEGRATION», 2021.
- [2] «Machine Learning | An Introduction | by Gavin Edwards | Towards Data Science». <https://towardsdatascience.com/machine-learning-an-introduction-23b84d51e6d0> (consulta 12 octubre 2022).
- [3] N. Kühl, M. Goutier, R. Hirt, i G. Satzger, «Machine Learning in Artificial Intelligence: Towards a Common Understanding», març 2020.
- [4] «Supervised vs. Unsupervised Learning: What's the Difference? | IBM». <https://www.ibm.com/cloud/blog/supervised-vs-unsupervised-learning> (consulta 12 octubre 2022).
- [5] «What are Neural Networks? | IBM». <https://www.ibm.com/topics/neural-networks> (consulta 2 desembre 2022).
- [6] «Hidden Layer Definition | DeepAI». <https://deepai.org/machine-learning-glossary-and-terms/hidden-layer-machine-learning> (consulta 2 desembre 2022).
- [7] A. L. Palmer Pol i J. J. Montaña Moreno, «¿Qué son las redes neuronales artificiales? Aplicaciones realizadas en el ámbito de las adiciones», *Adicciones: Revista de sociodrogalcohol*, ISSN 0214-4840, Vol. 11, Nº. 3, 1999, págs. 243-255, vol. 11, núm. 3, p. 243-255, 1999, Consulta: 3 desembre 2022. [En línia]. Disponible a: <https://dialnet.unirioja.es/servlet/articulo?codigo=4473964>
- [8] S. Sharma, S. Sharma, i A. Athaiya, «ACTIVATION FUNCTIONS IN NEURAL NETWORKS», *International Journal of Engineering Applied Sciences and Technology*, vol. 4, p. 310-316, 2020, Consulta: 4 desembre 2022. [En línia]. Disponible a: <http://www.ijeast.com>
- [9] D. Bank, N. Koenigstein, i R. Giryes, «Autoencoders».
- [10] A. Sherstinsky, «Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) network», *Physica D*, vol. 404, p. 132306, març 2020, doi: 10.1016/J.PHYSD.2019.132306.
- [11] P. Agustí, «paupaf3/tfg-anomaly-detection». <https://github.com/paupaf3/tfg-anomaly-detection> (consulta 30 maig 2023).

- [12] «Step-by-step understanding LSTM Autoencoder layers | by Chitta Ranjan | Towards Data Science». <https://towardsdatascience.com/step-by-step-understanding-lstm-autoencoder-layers-ffab055b6352> (consulta 21 gener 2023).
- [13] «Activation Functions : Sigmoid, tanh, ReLU, Leaky ReLU, PReLU, ELU, Threshold ReLU and Softmax basics for Neural Networks and Deep Learning | by Himanshu S | Medium». <https://himanshuxd.medium.com/activation-functions-sigmoid-relu-leaky-relu-and-softmax-basics-for-neural-networks-and-deep-8d9c70eed91e> (consulta 21 maig 2023).
- [14] «Dropout layer». https://keras.io/api/layers/regularization_layers/dropout/ (consulta 11 març 2023).
- [15] X. Li *et al.*, «An Overview of Overfitting and its Solutions You may also like Multi-Stage Two Point Incremental Sheet Forming Research on Robot Trajectory Planning Strategy for Water Polo Confrontation An Overview of Overfitting and its Solutions», p. 22022, 2019, doi: 10.1088/1742-6596/1168/2/022022.
- [16] «BatchNormalization layer». https://keras.io/api/layers/normalization_layers/batch_normalization/ (consulta 12 març 2023).
- [17] «Mean squared error - IBM Documentation». <https://www.ibm.com/docs/en/cloud-paks/cp-data/3.5.0?topic=overview-mean-squared-error> (consulta 4 febrer 2023).
- [18] «Introducción a los codificadores automáticos | TensorFlow Core». <https://www.tensorflow.org/tutorials/generative/autoencoder?hl=es-419> (consulta 22 abril 2023).
- [19] «Confusion Matrix». <https://devopedia.org/confusion-matrix> (consulta 14 maig 2023).